

wordle

Strategie für wordle



Was ist Wordle?

Gibt es eine Strategie für Wordle?



Strategie für Wordle

Ziel: Minimierung der Zugzahl




Wie finden wir das optimale Anfangswort, um Wordle in möglichst wenigen Zügen zu lösen?

Anfangswort

Erste Heuristik: Positions-Wahrscheinlichkeiten

1. Gesamten Antwortwortschatz durchzählen.
2. Für jede Position die Häufigkeit aller 26 Buchstaben bestimmen.
3. $\text{Score}(w) = \text{Summe der fünf Einzelwahrscheinlichkeiten.}$



Erste Heuristik:

Positions-Wahrscheinlichkeiten

$$\Sigma = \{A, B, \dots, Z\}$$

$$D = \{x \in \Sigma^5 \mid x \text{ ist in Datenbank}\}$$

Anfangswort $w \in D$

Für alle Position i und Buchstabe l :

$$P(x_i = l) = \frac{|\{x \in D : x_i = l\}|}{|D|}$$

$$\text{Score} = \sum_{i=1}^5 P(i_{te} \text{ Buchstabe} = w_i)$$

Gedanke: Hoher Score \Rightarrow Wort sieht „typisch“ wie eine Lösung aus.

Das heißt, es gibt viele grüne/gelbe Felder

Positions-Wahrscheinlichkeiten

Beispiel:

PRINT, POINT, WATER, WASTE, PONNY, POWER, SNACK, SLEEP, SLICE, FANCY

P	0.4	R	0.1	I	0.3	N	0.3	T	0.2
P	0.4	O	0.3	I	0.3	N	0.3	T	0.2
W	0.2	A	0.3	T	0.1	E	0.3	R	0.2
W	0.2	A	0.3	S	0.1	T	0.1	E	0.2
P	0.4	O	0.3	N	0.2	N	0.3	Y	0.2
P	0.4	O	0.3	W	0.1	E	0.3	R	0.2
S	0.3	N	0.1	A	0.1	C	0.3	K	0.1
S	0.3	L	0.2	E	0.1	E	0.3	P	0.1
S	0.3	L	0.2	I	0.3	C	0.3	E	0.2
F	0.1	A	0.3	N	0.2	C	0.3	Y	0.2

1.3
1.5
1.1
0.9
1.4
1,3
0.9
1.0
1.3
1.1

Das bedeutet: POINT ist das Beste Anfangswort.

POSITIONS-Wahrscheinlichkeiten

Python --- Pseudocode

Algorithm 1 Main

```
1: procedure MAIN
2:   0. Initialisierung
3:   Set random seed  $\leftarrow$  RANDOM_SEED
4:   posProbs  $\leftarrow$  POSITIONALPROBABILITIES(WORD_LIST)
5:   rows  $\leftarrow$  empty list

6:   1. Schleife über alle Kandidaten als guess
7:   for all guess  $\in$  WORD_LIST do
8:     g_total  $\leftarrow$  0 ▷ Gesamtzahl grüner Felder
9:     y_total  $\leftarrow$  0 ▷ Gesamtzahl gelber Felder
10:    for i  $\leftarrow$  1 to N_SAMPLES do
11:      ans  $\leftarrow$  random choice from WORD_LIST
12:      fb  $\leftarrow$  FEEDBACK(guess, ans)
13:      g_total  $+=$  count("G", fb)
14:      y_total  $+=$  count("Y", fb)
15:    end for
16:    avg_g  $\leftarrow$  g_total/N_SAMPLES
17:    avg_y  $\leftarrow$  y_total/N_SAMPLES
18:    avg_total  $\leftarrow$  avg_g + avg_y
19:    score  $\leftarrow$  WORDSCORE(guess, posProbs)
20:    ROWS.APPEND({
      word: guess,
      score_sum: round(score, 3),
      avg_green: round(avg_g, 3),
      avg_yellow: round(avg_y, 3),
      avg_total: round(avg_total, 3)
    })
21: end for

22: DataFrame erstellen und sortieren
23: df  $\leftarrow$  DataFrame(rows) ▷ sortiert nach score_sum absteigend
24: corr  $\leftarrow$  CORRELATION(df[score_sum], df[avg_total])

25: Ausgabe
26: PRINT(df)
27: PRINT("Correlation between score_sum and avg_total:", corr)
28: end procedure
```

Positions-Wahrscheinlichkeiten

Python --- Ergebnis

Freie Universität



Berlin

Beispiel:

PRINT, POINT, WATER, WASTE, PONNY, POWER, SNACK, SLEEP, SLICE, FANCY

word	score_sum	avg_green	avg_yellow	avg_total
POINT	1.5	1.546	0.484	2.030
PONNY	1.4	1.365	0.194	1.559
PRINT	1.3	1.298	0.670	1.968
POWER	1.3	1.305	0.610	1.915
SLICE	1.3	1.304	0.393	1.697
WATER	1.1	1.074	0.790	1.864
FANCY	1.1	1.080	0.429	1.509
SLEEP	1.0	1.083	0.687	1.770
WASTE	0.9	0.906	1.114	2.020
SNACK	0.9	0.888	0.809	1.697

Correlation between score_sum and avg_total: 0.094

Schlecht!!



vereinfachter Fall

- Die Sequenz ist dreistellig.
- Jede Position darf nur die Ziffer 0, 1 oder 2 enthalten.
- (erste Stelle \geq zweite Stelle \geq dritte Stelle)

Welche Ziffer rate ich zuerst an der ersten Stelle der dreistelligen Zahl?

2

Warum 2?

000

100

110

111

200

210

211

220

221

222

vereinfachter Fall

0	000	1
1	100 110 111	3
2	200 210 211 220 221 222	6

0	$S_{0,p(0)} = 1$ $S_{0,p(1)} = 9$ $S_{0,p(2)} = 9$	$19/3$ $\text{Max}=9$
1	$S_{1,p(0)} = 7$ $S_{1,p(1)} = 3$ $S_{1,p(2)} = 7$	$17/3$ $\text{Max}=7$
2	$S_{2,p(0)} = 4$ $S_{2,p(1)} = 4$ $S_{2,p(2)} = 6$	$14/3$ $\text{Max}=6$

000
100
110
111
200
210
211
220
221
222

2 ist am besten

Vereinfachter Fall

Freie Universität



Berlin

Welche dreistellige Zahl sollte man als ersten Tipp wählen, um die beste Ausgangsposition zu haben?

210?



vereinfachter Fall

$$ExpRem = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}|$$

$$WorstRem = \max_p |S_{w,p}|$$

Anfang:	000
x√√	100, 200
xx√	110, 210, 220
xxx	111, 211, 221, 222

Anfang:	100
x√√	000, 200
xx√	210, 220
xxx	211, 221, 222
√x√	110
√xx	111

000

100

110

111

200

210

211

220

221

222

2.9

4

1.9

3

vereinfachter Fall

Anfang:	110
x√√	210
xx√	000, 200, 220
xxx	221, 222
√x√	100
√√x	111
x√x	211

Anfang:	111
x√√	211
xx√	221
xxx	000, 200, 220, 222
√√x	110
x√x	210
√xx	100

$$ExpRem = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}|$$

$$WorstRem = \max_p |S_{w,p}|$$

1.7

3

2.1

4

000

100

110

111

200

210

211

220

221

222

vereinfachter Fall

Anfang:	200
x√√	000, 100
xx√	110
xxx	111
√x√	210, 220
√xx	211, 221, 222

Anfang:	210
x√√	110
xx√	000, 100
√x√	200, 220
√√x	211
x√x	111
√xx	221, 222

$$ExpRem = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}|$$

$$WorstRem = \max_p |S_{w,p}|$$

000

100

110

111

200

210

211

220

221

222

1.9

3

1.5

2

vereinfachter Fall

$$ExpRem = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}|$$

$$WorstRem = \max_p |S_{w,p}|$$

Anfang:	211
x√√	111
xxx	000, 100
√x√	221
√√x	210
x√x	110
√xx	200, 220, 222

Anfang:	220
xx√	000, 100, 110
xxx	111
√x√	200, 210
√√x	221, 222
√xx	211

1.7

3

1.9

3

000

100

110

111

200

210

211

220

221

222

vereinfachter Fall

$$ExpRem = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}|$$

$$WorstRem = \max_p |S_{w,p}|$$

Anfang:	221
xx√	111
xxx	000, 100, 110
√x√	211
√√x	220, 222
√xx	200, 210

Anfang:	222
xxx	000, 100, 110, 111
√√x	220, 221
√xx	200, 210, 211

1.9

3

2.9

4

000

100

110

111

200

210

211

220

221

222

vereinfachter Fall

$$\text{ExpRem} = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}| \quad \text{WorstRem} = \max_p |S_{w,p}|$$

000	2.9	4
100	1.9	3
110	1.7	3
111	2.1	4
200	1.9	3
210	1.5	2
211	1.7	3
220	1.9	3
221	1.9	3
222	2.9	4

Restmenge

Beispiel:

PRINT, POINT, PRISM, POWER, PRAYS, PRIME

Grün -----2
Gelb -----1
Grau -----0

W = POWER

$$P(PRINT) = (20001)$$

$$P(POINT) = (22000)$$

$$P(PRISM) = (20001)$$

$$P(PRAYS) = (20001)$$

$$P(PRIME) = (20011)$$

$$|S_{w,p(PRINT)}| = 3$$

$$|S_{w,p(POINT)}| = 1$$

$$|S_{w,p(PRISM)}| = 3$$

$$|S_{w,p(PRAYS)}| = 3$$

$$|S_{w,p(PRIME)}| = 1$$

$$|S_{w,(20001)}| = 3$$

$$|S_{w,(22000)}| = 1$$

$$|S_{w,(20011)}| = 1$$

$$ExpRem = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}| = \frac{1}{6} (3 + 1 + 3 + 3 + 1)$$

$$WorstRem = \max_p |S_{w,p}| = 3$$

Restmenge

Beispiel:

PRINT, POINT, PRISM, POWER, PRAYS, PRIME

Grün -----2

Gelb -----1

Grau -----0

W = PRISM

$$P(PRINT) = (22200)$$

$$P(POINT) = (20200)$$

$$P(POWER) = (21000)$$

$$P(PRAYS) = (22000)$$

$$P(PRIME) = (22201)$$

$$|S_{w,p(PRINT)}| = 1$$

$$|S_{w,p(POINT)}| = 1$$

$$|S_{w,p(POWER)}| = 1$$

$$|S_{w,p(PRAYS)}| = 1$$

$$|S_{w,p(PRIME)}| = 1$$

$$|S_{w,(22200)}| = 1$$

$$|S_{w,(20200)}| = 1$$

$$|S_{w,(21000)}| = 1$$

$$|S_{w,(22000)}| = 1$$

$$|S_{w,(22201)}| = 1$$

$$ExpRem = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}| = \frac{1}{6} (1 + 1 + 1 + 1 + 1)$$

$$WorstRem = \max_p |S_{w,p}| = 1$$

Restmenge

In diesen Fall ist **PRISM** ein bessere Anfangswort.



Als nächsten Schritt haben wir zur Überprüfung mit Python auch die folgenden zwölf Wörter getestet:

PRINT, PRIME, PRISM, POINT, PRAYS, POWER,
WATER, WASTE, SNACK, SLEEP, SLICE, SNAKE

Algorithm 1 Berechnung von **ExpRem** für alle Startwörter

```

1: procedure COMPUTEEXPREM(WORD_LIST)
2:   for all  $w \in \text{WORD\_LIST}$  do                                     ▷ alle möglichen Tipps
3:      $sum \leftarrow 0$ 
4:     for all  $a \in \text{WORD\_LIST}$  do                                     ▷ jede Kandidatenlösung
5:        $p \leftarrow \text{FEEDBACK}(w, a)$ 
6:        $k \leftarrow \text{REMAININGSIZE}(g, p, \text{WORD\_LIST})$ 
7:        $sum \leftarrow sum + k$                                        ▷  $|S_{w,p(a)}|$ 
8:     end for
9:      $\text{ExpRem}[w] \leftarrow \frac{sum}{|\text{WORD\_LIST}|}$ 
10:  end for
11:  return ExpRem
12: end procedure

```

$$\text{ExpRem} = \frac{1}{|S|} \sum_{a \in S} |S_{w,p(a)}|$$

Algorithm 2 Hilfsfunktionen

```

1: function FEEDBACK( $word, answer$ )
2:   return Musterstring aus 2 (grün), 1 (gelb), 0 (grau)
3: end function
4: function REMAININGSIZE( $w, p, S$ )
5:   return Anzahl der Wörter  $c \in S$  mit  $\text{FEEDBACK}(w, c) = p$ 
6: end function

```

Algorithm 3 Berechnung von **WorstRem** für alle Startwörter

```

1: procedure COMPUTEWORSTREM(WORD_LIST)
2:   for all  $w \in \text{WORD\_LIST}$  do                                     ▷ aktuelles Startwort
3:      $maxSize \leftarrow 0$ 
4:      $seen \leftarrow$  leeres Dictionary                               ▷ gemerkte Muster
5:     for all  $a \in \text{WORD\_LIST}$  do                                     ▷ jede Kandidatenlösung
6:        $p \leftarrow \text{FEEDBACK}(w, a)$                                ▷ Muster für  $w$  gegen  $a$ 
7:       if  $p \notin seen$  then                                       ▷ je Pattern nur einmal zählen
8:          $k \leftarrow \text{REMAININGSIZE}(w, p, \text{WORD\_LIST})$ 
9:          $seen[p] \leftarrow k$ 
10:         $maxSize \leftarrow \max(maxSize, k)$ 
11:      end if
12:    end for
13:     $\text{WorstRem}[w] \leftarrow maxSize$                                ▷ größtes Rest-Set für  $w$ 
14:  end for
15:  return WorstRem                                               ▷ Map: Wort  $\rightarrow$  WorstRem
16: end procedure

```

$$\text{WorstRem} = \max_p |S_{w,p}|$$

Restmenge

Python --- Ergebnis

Beispiel:

PRINT, PRIME, PRISM, POINT, PRAYS, POWER,
WATER, WASTE, SNACK, SLEEP, SLICE, SNAKE

Word	ExpRem	AvgSteps
WATER	1.000000	1.916667
PRIME	1.166667	2.000000
SNAKE	1.166667	2.000000
PRINT	1.333333	2.083333
PRAYS	1.333333	2.083333
WASTE	1.333333	2.083333
SNACK	1.333333	2.083333
SLEEP	1.333333	2.083333
SLICE	1.333333	2.083333
PRISM	1.500000	2.083333
POINT	1.500000	2.166667
POWER	1.666667	2.166667

Word	WorstRem	AvgSteps
WATER	1	1.916667
PRINT	2	2.083333
PRIME	2	2.000000
POINT	2	2.166667
PRAYS	2	2.083333
WASTE	2	2.083333
SNACK	2	2.083333
SLEEP	2	2.083333
SLICE	2	2.083333
SNAKE	2	2.000000
PRISM	3	2.083333
POWER	3	2.166667

Korrelation: 0.94



Korrelation: 0.67



Restmenge

Python --- Ergebnis

Mit 50 Wörter:

PRINT, PRIME, PRISM, POINT, PRAYS, POWER, WATER, WASTE,
SNACK, SLEEP, SLICE, SNAKE, CRANE, SLATE, TRACE, CRISP, GRACE,
PLANT, GRANT, PRIDE, TRICE, IDEAL, APPLE, BERRY, CHASE, DELTA,
EARTH, FAITH, GIANT, HAPPY, INDEX, JUDGE, KNIFE, LEMON, MAGIC,
NOVEL, OCEAN, PEACH, QUIET, RIVER, SOLAR, TIGER, UNITY, VIVID,
WHALE, XENON, YEAST, ZEBRA, CABIN, DANCE

ExpRem Korrelation: 0.89

WorstRem Korrelation: 0.88



Restmenge

Python --- Ergebnis

Mit 1000 Wörter:

ExpRem Korrelation: 0.86

WorstRem Korrelation: 0.82

AREAS ist das Beste Anfangswort

ARISE ist das Beste Anfangswort



Mit 14855 Wörter:

ExpRem

WorstRem

LARES ist das Beste Anfangswort


SERIA ist das Beste Anfangswort

Weitere Fragen



Wie kann man das Rechnen vereinfachen, um die Laufzeit zu reduzieren?

Gibt es noch bessere Methoden mit theoretischer Grundlagen?



In der Zukunft...

1. Algorithmus beschleunigen

$|S_{w,p}|$

um Wiederholung zu vermeiden

2. Weitere Kennzahlen evaluieren

1. Vergleich mit Informationsgewinn / Entropie / erwarteten Zügen (Expected Steps).
2. Robustheitstests: Wie stabil ist die Rangfolge bei veränderten Wortlisten?

3. Größere und diversere Wortlisten

Erweiterung auf 6-Buchstaben-Varianten oder andere Sprachen.



P	O	I	N	T
S	N	A	K	E
P	I	A	N	O
P	L	A	I	N

VIELEN DANK

Q	W	E	R	T	Y	U	I	O	P
A	S	D	F	G	H	J	K	L	
ENTER	Z	X	C	V	B	N	M	⌫	